



SLOVENSKÁ TECHNICKÁ
UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY
A INFORMATIKY

ŠTUDIJNÝ MATERIÁL

Odporúčané ukážky kódu

Projekt 1 · Hlboké neurónové siete

Verejné implementácie mechanizmu pozornosti, vizuálnych transformerov a hybridných sietí. Odkazy slúžia na čítanie a na porovnanie s vlastnou prácou.

Fakulta elektrotechniky a informatiky · Slovenská technická univerzita v Bratislave · september 2026

1 Účel materiálu

Materiál zhromažďuje overené verejné ukážky k modelom, s ktorými sa pracuje v Projekte 1: škálovaná skalárna pozornosť, transformerový blok a jeho prenos z textu na klasifikáciu obrazu.

Záväzný rozsah ostáva v zadaní projektu a v troch notebookoch predmetu. Tento dokument k nim pridáva zdroje, z ktorých sa tie isté modely dajú naštudovať v pôvodnej podobe.

Notebook 01 stavia pozornosť od nuly a končí znakovým jazykovým modelom. **Notebook 02** prenáša ten istý blok na obraz: patch embedding, mini-ViT, DeiT, Swin, ConvNeXt, CBAM a CoAtNet. **Notebook 03** porovnáva šesť architektúr na desaťtriednej podmnožine Food-101 za spoločného tréningového receptu.

2 Ako s odkazmi pracovať

Každý model má viac verejných implementácií. Pri predmete majú zmysel tri vrstvy, v tomto poradí.

1

Implementácia na čítanie

Krátky kód, v ktorom je vidieť každá vrstva. Sem patrí prednáška Andreja Karpathyho a anotovaný Vision Transformer.

2

Knižnica na spustenie

Predtrénované váhy a doladenie sa v notebookoch predmetu načítavajú cez timm. Toto je cesta, ktorou sa modely v Projekte 1 reálne používajú.

3

Repozitár k článku

Oficiálny kód Swin, ConvNeXt a DeiT je tréningový systém na ImageNet. Číta sa kvôli definícii architektúry a pôvodnému receptu.

3 Pozornosť a transformer od nuly

Notebook 01 ide tou istou postupnosťou ako Karpathyho prednáška: korpus Tiny Shakespeare, bigramový model, dolná trojuholníková maska, škálovaný skalárny súčin, viac hláv a blok s LayerNorm a reziduálnym spojením.

Prednáška a kód, ktorý notebook sleduje

- [Let's build GPT: from scratch, in code, spelled out.](#)

www.youtube.com/watch?v=kCc8FmEb1nY

Video stavia dekodérový transformer od prázdneho súboru. Postup je zhodný s notebookom 01: najprv model bez kontextu, potom vážená agregácia minulosti, potom pozornosť počítaná z dát.

- [Repozitár k prednáške](#)

github.com/karpathy/ng-video-lecture

- [Colab k prednáške](#)

colab.research.google.com/drive/1JMLa53HDuA-i7ZBmqV7ZnA3c_fvtXnx-?usp=sharing

Kratšia podoba toho istého modelu

- [nanoGPT, súbor model.py](#)

github.com/karpathy/nanoGPT/blob/master/model.py

Ten istý dekodérový transformer, zhrnutý do jedného súboru. Vhodné ako kontrola, keď je vlastná implementácia hotová a treba ju porovnať s čistou verziou.

Pôvodný článok a krížová pozornosť

- [The Annotated Transformer](#)

nlp.seas.harvard.edu/annotated-transformer/

Anotovaný preklad článku Attention Is All You Need do PyTorch. Je tu enkodér aj dekodér a krížová pozornosť, ktorú notebook 01 len naznačuje.

- [Vaswani et al., 2017. Attention Is All You Need.](#)

arxiv.org/abs/1706.03762

4 Vizuálny transformer od nuly

V notebooku 02 vzniká mini-ViT z tých istých dielov ako jazykový model. Zmení sa prevod vstupu na sekvenciu a vypadne kauzálna maska: pri obraze je celý vstup dostupný naraz. Patch embedding je jedna konvolúcia, ktorej krok aj veľkosť jadra sa rovnajú veľkosti patchu.

- [labml.ai — Vision Transformer](#)

nn.labml.ai/transformers/vit/index.html

PyTorch so sprievodným textom vedľa kódu: patch embedding, naučené pozičné embeddingy, CLS token a klasifikačná hlava. Súčasťou je aj beh na malých dátach. ViT trénovaný od nuly na málo obrázkoch zostáva slabý, čo je záver časti 6 notebooku 02.

- [lucidrains/vit-pytorch](#)

github.com/lucidrains/vit-pytorch

Krátka trieda ViT a príklad destilácie z konvolučného učiteľa. Destilácia je myšlienka, na ktorej stojí DeiT. Ďalšie varianty v tom istom repozitári predmet nepotrebuje.

- [Oficiálna implementácia v JAX](#)

github.com/google-research/vision_transformer

- [Dosovitskiy et al., 2021. An Image is Worth 16x16 Words.](#)

arxiv.org/abs/2010.11929

5 Architektúry z porovnania

Notebook 03 porovnáva šesť modelov predtrénovaných na ImageNet-1k. Váhy sa načítavajú z knižnice timm. Tabuľka vedie k súboru, v ktorom je daná architektúra zapísaná, a k zdroju, z ktorého pochádza.

Model	Kód na čítanie a použitie	Oficiálny zdroj
DeiT-Tiny <i>Globálna self-attention. V predmete ide o doladenie predtrénovaného ViT.</i>	timm, deit.py github.com/huggingface/pytorch-image-models/blob/main/timm/models/deit.py	facebookresearch/deit github.com/facebookresearch/deit
Swin-T <i>Okenná pozornosť a hierarchia rozlíšení.</i>	timm, swin_transformer.py github.com/huggingface/pytorch-image-models/blob/main/timm/models/swin_transformer.py	Swin-Transformer github.com/microsoft/Swin-Transformer
ConvNeXt-T <i>Konvolučná sieť modernizovaná podľa transformerov. Bez vrstvy pozornosti.</i>	timm, convnext.py github.com/huggingface/pytorch-image-models/blob/main/timm/models/convnext.py	facebookresearch/ConvNeXt github.com/facebookresearch/ConvNeXt
ConvNeXt-T + CBAM <i>Tá istá sieť, kanálová a priestorová pozornosť za štádiami.</i>	Oficiálny modul cbam.py github.com/Jongchan/attention-module/blob/master/MODELS/cbam.py Vloženie za štádiá ConvNeXt je v notebooku 02.	Jongchan/attention-module github.com/Jongchan/attention-module
CoAtNet-0 <i>Konvolúcie v skorých štádiách, relatívna self-attention v neskorých.</i>	coatnet-pytorch github.com/chinhquanwu/coatnet-pytorch Čitateľná implementácia v jednom súbore. V predmete sa váhy načítavajú z timm.	Článok CoAtNet arxiv.org/abs/2106.04803
EfficientNet-B0 <i>Konvolučná referencia v porovnaní šiestich modelov.</i>	timm, efficientnet.py github.com/huggingface/pytorch-image-models/blob/main/timm/models/efficientnet.py	Článok EfficientNet arxiv.org/abs/1905.11946

Knižnica timm ako celok: huggingface/pytorch-image-models. Dokumentácia je na huggingface.co/docs/timm.

6 Načítanie predtrénovaných váh

Všetky predtrénované modely v notebookoch 02 a 03 vznikajú jedným volaním. Výmena klasifikačnej hlavy je parameter `num_classes`. Názov reťazca určuje architektúru aj konkrétny checkpoint naučený na ImageNet-1k.

```
import timm

model = timm.create_model(
    "deit_tiny_patch16_224.fb_in1k",
    pretrained=True,
    num_classes=10,
)
```

Ďalšie názvy z notebookov, v tom istom volaní:

Názov v knižnici timm	Architektúra
deit_tiny_patch16_224.fb_in1k	DeiT-Tiny
swin_tiny_patch4_window7_224.ms_in1k	Swin-T
convnext_tiny.fb_in1k	ConvNeXt-T
coatnet_0_rw_224.sw_in1k	CoAtNet-0
efficientnet_b0	EfficientNet-B0

CBAM sa vkladá ako modul za štádiá už načítaného ConvNeXt-T. Vzor vloženia je v notebooku 02, samotný modul v `cbam.py` z odkazu v tabuľke vyššie.

Pri EfficientNet-B0 stačí názov efficientnet_b0. Pri ostatných modeloch treba použiť celý reťazec vrátane prípony checkpointu, aby všetky siete vychádzali z váh ImageNet-1k a porovnanie zostalo férové.

7 Mapy pozornosti

Notebook 02 vykresľuje, na ktoré patche sa pozerá CLS token. Jedna mapa z poslednej vrstvy na to nestačí, lebo reziduálne spojenia miešajú informáciu cez hĺbku siete. Attention rollout mapy cez vrstvy vynásobí a k reziduám pripočíta identitu.

- [Abnar, Zuidema, 2020. Quantifying Attention Flow in Transformers.](#)

arxiv.org/abs/2005.00928

- [Implementácia attention flow](#)

github.com/samiraabnar/attention_flow

Mapa ukazuje, kadiaľ tečie informácia. Nie je vysvetlením toho, prečo model vybral triedu. Na príspevok k rozhodnutiu slúžia iné metódy, napríklad Grad-CAM.

8 Literatúra

1. Vaswani, A. et al. (2017). Attention Is All You Need. NeurIPS. arxiv.org/abs/1706.03762
2. Dosovitskiy, A. et al. (2021). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR. arxiv.org/abs/2010.11929
3. Touvron, H. et al. (2021). Training data-efficient image transformers & distillation through attention. ICML. arxiv.org/abs/2012.12877
4. Liu, Z. et al. (2021). Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. ICCV. arxiv.org/abs/2103.14030
5. Liu, Z. et al. (2022). A ConvNet for the 2020s. CVPR. arxiv.org/abs/2201.03545
6. Woo, S. et al. (2018). CBAM: Convolutional Block Attention Module. ECCV. arxiv.org/abs/1807.06521
7. Dai, Z. et al. (2021). CoAtNet: Marrying Convolution and Attention for All Data Sizes. NeurIPS. arxiv.org/abs/2106.04803
8. Tan, M., Le, Q. V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. ICML. arxiv.org/abs/1905.11946
9. Bossard, L., Guillaumin, M., Van Gool, L. (2014). Food-101 – Mining Discriminative Components with Random Forests. ECCV.
10. Abnar, S., Zuidema, W. (2020). Quantifying Attention Flow in Transformers. ACL. arxiv.org/abs/2005.00928

9 Odporúčané poradie

1. Karpathyho prednáška a jej notebook. Pozornosť, maska a transformerový blok.
2. Anotovaný ViT na labml.ai. Patch embedding, CLS token a nemaskovaná pozornosť.
3. Súbor v timm pre ten model, ktorý práve dopĺňate o predtrénované váhy.
4. Oficiálny repozitár článku až vo chvíli, keď potrebujete pôvodnú definíciu architektúry alebo tréningový recept na ImageNet. Notebooky 01 až 03 sú verzia týchto modelov v rozsahu Projektu 1.