

Experimentálne porovnanie CNN, ViT a Hybridných modelov


Dataset

Použili sme desaťtriednu podmnožinu datasetu **Food-101** [8]. Triedy neboli vybrané náhodne – obsahujú tri dvojice vizuálne veľmi podobných jedál: spaghetti_bolognese ↔ spaghetti_carbonara, ice_cream ↔ frozen_yogurt a filet_mignon ↔ steak. Zvyšné štyri triedy (pizza, sushi, caesar_salad, chocolate_cake) sú ľahko odlišiteľné.


Zámerom bolo, aby sa presnosť nenásýtila blízko 100 % a aby v matici zámien bolo vidieť skutočný rozdiel medzi architektúrami. Oficiálny trénovací split sme stratifikovane rozdelili na 6 750 trénovacích a 750 validačných obrázkov; oficiálny testovací split (2 500 obrázkov) slúžil výhradne na finálne vyhodnotenie.

Model	Kategória	Param. [M]	GFLOPs	Test [%]	Čas/ep. [s]	Inferencia [obr./s]
EfficientNet-B0	CNN	4.02	0.77	87.20	8	5291
ConvNeXt-T	CNN (hierarchická)	27.83	8.91	92.40	12	2355
ConvNeXt-T + CBAM	CNN + attention	27.93	8.91	92.80	13	2219
CoAtNet-0	Hybrid	26.67	8.81	94.04	17	1802
Swin-T	ViT (hierarchický)	27.53	8.98	93.60	14	1766
DeiT-T	ViT (izotropný)	5.53	2.51	90.84	3	10999


Tabuľka 3: Porovnanie architektúr na 10 triedach Food-101. Všetky modely trénované identickým receptom, predtrénované na ImageNet-1k.




Obr. 1: Testovacia presnosť jednotlivých architektúr.




Obr. 2: Priebeh validačnej presnosti a straty počas 12 epôch.



Obr. 3: Presnosť v pomere k veľkosti modelu a k rýchlosti inferencie.



Obr. 4: Presnosť po triedach. Najnižšie hodnoty sú sústredené vo vizuálne podobných dvojiciach.



Obr. 5: Matice zámien (hodnoty v percentách v rámci riadku).